

**CERTIFICATION PROFESSIONNELLE EXPERT INGENIERIE DES DONNEES
RNCP36921**

BLOC 2 - Pilotage d'un projet de développement d'une plateforme Big Data
(architecture et infrastructure) dans un environnement agile
BLOC 4 - Administration et supervision d'une plateforme Big Data

Cahier des Charges de la MSPR « Administration et supervision d'une plateforme Big Data sécurisée selon les principes agiles dans un environnement multiculturel »

COMPÉTENCES ÉVALUÉES :**Bloc 2 - Pilotage d'un projet de développement d'une plateforme Big Data (architecture et infrastructure) dans un environnement agile**

- Identifier l'ensemble des étapes de réalisation du développement d'une plateforme Big Data pour organiser le projet en tâches et livrables en répartissant les activités en fonction des ressources humaines, techniques et financières à mobiliser.
- Concevoir les cahiers des charges technique et fonctionnel d'un projet de développement d'une plateforme Big Data à l'aide des besoins utilisateurs collectés afin de cadrer le développement.
- Gérer un projet agile en utilisant les méthodes et outils adaptés à ce mode de fonctionnement pour tester, modifier et procéder par itération afin de réduire les délais de remise du projet de développement d'une plateforme Big Data.
- Etablir des tableaux de bord de suivi de performance (qualitative et quantitative) de l'ensemble des ressources allouées à chaque étape-projet pour anticiper, visualiser et corriger les écarts en temps réel afin de limiter les contraintes de ressources et les retards dans la réalisation du projet
- Piloter les prestataires extérieurs éventuels gérant les ressources informatiques d'une plateforme de données existante listées dans la cartographie établie afin de sécuriser la mise en œuvre technique.
- Conduire une équipe projet en diffusant les fondamentaux de l'agilité : adaptation, flexibilité et amélioration continue au sein de l'équipe afin d'être en mesure d'absorber les changements de priorité qui peuvent intervenir dans un contexte de forte contrainte de temps et d'incertitudes.
- Adopter une stratégie d'accueil aux handicaps afin de favoriser l'inclusion des profils en situation de handicap au sein de l'équipe et permettre leur pleine intégration, en collaboration avec le référent handicap de l'entreprise.
- Concevoir un processus de communication inclusif régulier au sein de l'équipe afin de synchroniser les activités quotidiennes et mettre en place un fil de discussion à l'aide d'outils numériques.
- Animer des réunions à distance afin de maintenir une dynamique de groupe et renforcer l'esprit d'équipe des membres en télétravail et/ou à distance.
- Concevoir un processus de partage d'information afin de faciliter l'inclusion et la collaboration entre les membres en télétravail et/ou à distance en utilisant des outils numériques.

Bloc 4 - Administration et supervision d'une plateforme Big Data

- Déployer une plateforme de stockage de données, dans un environnement distribué à travers des clusters de nœuds (serveurs machine) afin d'y stocker les données de façon distribuée et de les traiter selon le principe du calcul parallèle.
- Configurer des clusters de nœuds avec une solution de stockage distribuée afin d'assurer une tolérance de zéro panne.
- Automatiser des opérations de déploiement, de tests et de maintenance curative et préventive afin de s'assurer de la fiabilité de la solution tout au long de son cycle de vie.
- Concevoir un ensemble de tests de surveillance des pipelines afin d'anticiper et d'organiser l'évaluation et le dépannage des représentations de données.
- Administrer la plateforme de stockage de données déployée dans un environnement technologique optimal afin de répondre aux trois critères sinequa non tels que la performance, la capacité et la bande passante de la plateforme.
- Dimensionner en temps réel les besoins en consommation de ressources en mettant en place l'autoscaling des ressources afin d'anticiper les montées en charge et assurer la fiabilité de la solution.
- Contrôler la bonne application de la politique des données en analysant, traitant et reportant les coûts et les performances de stockage selon les différents critères (licences, supports, évolutivité, performance...) afin de s'assurer de la pérennité de la solution.
- Rédiger un protocole de maintenance de la documentation technique afin de consigner et assurer la préservation de la solution choisie

PHASE 1 : PRÉPARATION DE CETTE MISE EN SITUATION PROFESSIONNELLE RECONSTITUÉE

- **Durée de préparation** : 39 heures
- **Mise en œuvre** : Travail d'équipe constituée de 4 apprenants (5 maximum si groupe impair)

PHASE 2 : PRÉSENTATION ORALE COLLECTIVE + ENTRETIEN COLLECTIF

- **Objectif** : mettre en avant et démontrer que les compétences visées par ce bloc sont bien acquises.
- **Moyen** : L'équipe utilise un support de présentation
- **Durée totale par groupe** : 50 mn se décomposant comme suit :
 - 20 mn de soutenance orale par l'équipe.
 - 30 mn d'entretien collectif avec le jury (questionnement complémentaire).
- **Jury d'évaluation** : 2 personnes (binôme d'évaluateurs) par jury – Ces évaluateurs ne sont pas intervenus durant la période de formation et ne connaissent pas les apprenants à évaluer.

I - CONTEXTE




Vélib' est le service de vélos en libre-service de la ville de Paris, destiné à encourager une mobilité urbaine écologique. Dans le cadre du projet VélibData, la ville s'attache à développer un système intelligent de gestion des stations et des vélos, visant à garantir une répartition optimale des vélos tout au long de la journée. L'objectif est d'exploiter les données pour analyser les besoins des utilisateurs et anticiper les pics de demande et ainsi optimiser l'utilisation du service.

Pour mener à bien ce projet, VélibData prévoit de constituer trois équipes distinctes : une équipe de Data Analysts, une équipe de Data Scientists, et une autre de Data Engineers. Les Data Scientists seront chargés de développer des modèles de prédiction avancés, permettant d'anticiper les tendances et la demande en vélos. Les Data Analysts, quant à eux, se concentreront sur l'analyse approfondie des données existantes, en créant des tableaux de bord dynamiques pour suivre en temps réel l'évolution des flux et identifier les zones à optimiser.

Les Data Engineers, de leur côté, assureront l'architecture technique et la gestion des pipelines de données, garantissant une collecte et un traitement fluide des informations. Ils seront également responsables de la mise à disposition des outils nécessaires aux autres équipes, afin de faciliter l'accès, la transformation et l'analyse des données.

Dans ce contexte, la ville a mandaté un audit pour formuler des propositions concrètes pour la création de ce pôle. L'accent est particulièrement mis sur l'architecture de stockage des données, afin de garantir que les informations recueillies soient non seulement facilement accessibles, mais aussi modélisées de manière adéquate pour répondre aux besoins d'analyse.

La sécurité des données est également un aspect essentiel de cette démarche, afin d'assurer la protection des informations sensibles et de respecter les normes en vigueur. Cette phase préliminaire est cruciale pour assurer que l'infrastructure soit scalable, permettant ainsi une adaptation aux exigences futures du service, tout en veillant à la qualité et à la pertinence des données pour les analyses à venir.



II - SPÉCIFICATION DU BESOIN

Données

Pour mener à bien ce projet, deux apis seront utilisées:

1. **API de disponibilité des Velib en temps réel** : Cette API est mise à jour toutes les minutes, offrant des informations actualisées sur la disponibilité des vélos dans les différentes stations. Il est important de noter que, bien que les données soient fréquemment rafraîchies, il ne faut pas pousser l'aspect temps réel trop loin.
2. **API d'informations sur les stations Velib** : Cette API fournit des détails complets sur chaque station Velib, y compris sa localisation, sa capacité et son statut opérationnel.

Besoin

Le projet VélibData nécessite **une veille technologique approfondie** pour garantir que la meilleure infrastructure sera mise en place afin de répondre aux exigences de l'entreprise. Les différentes étapes à considérer dans ce processus comprennent :

- **Performance, alerte et scalabilité** : L'architecture doit être capable d'assurer des performances optimales, avec un système d'alerte en cas de **surcharge**, tout en permettant une scalabilité pour s'adapter aux besoins croissants.
- **Ingestion des données** : Évaluer les solutions permettant la collecte en temps réel des données provenant des API de localisation et de disponibilité des vélos.
- **Transformations des données** : Identifier les outils nécessaires pour le traitement, le nettoyage et la préparation des données afin d'assurer leur qualité et leur fiabilité.
- **Mise à disposition des utilisateurs externes** : Identifier les solutions pour garantir un accès optimal aux données pour les utilisateurs finaux et les analystes.

Vous devrez **développer l'infrastructure nécessaire au projet**, en mettant en place **l'architecture sous-jacente et les pipelines de données**. Vous devrez vous assurer que l'ensemble de l'architecture fonctionne de bout en bout.

Les attentes sont :

- **Création de l'infrastructure** : Concevoir et déployer l'architecture technique qui supportera la collecte, le stockage et le traitement des données.
- **Modélisation des données** : Proposer une **modélisation normalisée des données** qui facilite l'intégration et l'analyse des informations recueillies.
- **Pipeline de données** : Développer des pipelines de données permettant la **récupération en temps réel** des informations, ainsi que leur **traitement** et leur **stockage** de manière efficace. Vous devrez également mettre en place des **règles de qualité des données** et des **mécanismes d'alerte** pour détecter et signaler tout problème lié aux données.
- **Schéma d'architecture** : Construire un **schéma d'architecture qui illustre les flux de données** et les interactions entre les différentes composantes du système, accompagné d'explications sur les choix techniques effectués.
- **Plan de maintenance** : Élaborer un plan de maintenance pour le système, précisant **les actions à mener en cas de pannes** ou de défaillances, et suggérer des pistes d'amélioration si nécessaire.

Cette approche vous permettra non seulement de construire l'infrastructure requise, mais aussi de garantir son efficacité et sa durabilité face aux besoins croissants du projet.

III - LES CONTRAINTES IMPOSÉES PAR LE PROJET

- **Accès aux données** : Respect des limites imposées par l'API openweathermap, notamment en ce qui concerne le **nombre d'appels quotidiens**
- **Modélisation des données** : Établissement d'une base de données **normalisée** capable de gérer des **volumes croissants** de données et d'assurer une **requête efficace**.
- **Historisation** : Mise en place d'un système pour récupérer les données en temps réel et les stocker de manière systématique.
- **Qualité et fiabilité** : Mise en place d'un processus de **surveillance et d'alerte** concernant la qualité des données et la disponibilité des pipelines, ainsi que des mécanismes d'alerte en cas de problèmes sur la chaîne de pipeline ou de dégradation de la qualité des données.
- **Sécurité** : Conformité avec le **RGPD**, nécessitant une localisation des données en France ou dans l'UE et un accès sécurisé
- **Mise en place d'alertes** : Mise en place d'un processus de surveillance et d'alerte concernant la qualité des données et la disponibilité des pipelines.
- **Gestion de projet** : Adoption d'une approche **itérative** pour le développement, en **livrant un MVP qui sera amélioré progressivement**.

IV - LES LIVRABLES

Le dossier devra contenir l'ensemble des éléments demandé, en particulier des plans d'actions présentant à une Direction générale les principes adoptés et les principaux parcours usagers.

A ce titre, les livrables attendus sont :

- L'architecture technique qui supportera la collecte, le stockage et le traitement des données (conception et déploiement)
- Une modélisation normalisée des données qui facilite l'intégration et l'analyse des informations recueillies.
- Les pipelines de données permettant la récupération en temps réel des informations, ainsi que leur traitement et leur stockage de manière efficace. Expliquer les règles de qualité des données et des mécanismes d'alerte pour détecter et signaler tout problème lié aux données.
- Fournir un schéma d'architecture qui illustre les flux de données et les interactions entre les différentes composantes du système, accompagné d'explications sur les choix techniques effectués.
- Un plan de maintenance pour le système, précisant les actions à mener en cas de pannes ou de défaillances, et suggérer des pistes d'amélioration si nécessaire.
- Organisation de l'équipe : Description de la structure de l'équipe pour le projet, y compris les rôles et responsabilités de chaque membre.
- Méthodes de communication : Outils et méthodologies utilisés pour faciliter les échanges et la collaboration, tels que Agile, Trello, et Slack
- Organisation du travail : Décrire la manière dont vous vous êtes réparti les tâches, en mettant l'accent sur la collaboration et la communication tout au long du projet.
- Canaux de communication : Présenter les outils et méthodologies employés pour faciliter le partage d'informations et les échanges entre les membres de l'équipe, assurant ainsi une coordination efficace.

Ces livrables décrits sont un minimum des livrables, il convient de s'assurer que les compétences à démontrer sont bien présentes dans les livrables.

Pour votre projet, vous êtes libre d'utiliser les outils vus pendant les cours et/ou les outils utilisés dans votre entreprise.

En complément des livrables, l'équipe projet devra préparer un support de présentation destiné à la soutenance finale devant les commanditaires du projet.

Il est important de souligner que l'évaluation de cette MSPR repose sur la combinaison des trois éléments suivants :

- la qualité du travail réalisé au cours du projet,
- la pertinence et l'exhaustivité des livrables remis
- et la capacité de l'équipe à présenter, justifier et valoriser ce travail lors de la soutenance orale.

Les équipes devront donc s'assurer que les livrables reflètent bien l'ensemble des compétences attendues (cf. page 1), en démontrant à la fois la maîtrise technique et la capacité à communiquer efficacement auprès d'un client professionnel.